Universidad de Lima

Facultad de Ingeniería

Carrera de Ingeniería de Sistemas



Diseño e implementación de un sistema inteligente de recomendación de oportunidades de contratación pública de servicios basado en procesamiento de lenguaje natural para empresas en el Perú

Trabajo de investigación para optar el Título Profesional de Ingeniero de Sistemas

Sebastian Alonso Alvarez Dominguez
Código 20220109

Asesor
Edwin Escobedo

Lima – Perú
Setiembre de 2026

Diseño e implementación de un sistema inteligente de recomendación de oportunidades de contratación pública de servicios basado en procesamiento de lenguaje natural para empresas en el Perú

Sebastian Alvarez
20220109@aloe.ulima.edu.pe
Universidad de Lima

Resumen:

Abstract:

1. INTRODUCCIÓN

La contratación pública constituye un ámbito de aplicación del procesamiento de lenguaje natural, debido a la disponibilidad de registros y documentos que describen los servicios requeridos y los antecedentes de los proveedores. Su aprovechamiento puede apoyar la búsqueda de oportunidades; sin embargo, acceder a una convocatoria no permite determinar por sí solo su pertinencia para una empresa. En la contratación pública peruana de servicios, el problema abordado consiste en priorizar oportunidades a partir de la relación entre sus descripciones y la experiencia empresarial documentada, sin equiparar esa afinidad con el cumplimiento de todos los requisitos de participación.

Abordar este problema es importante porque permite orientar la revisión empresarial hacia oportunidades relacionadas con su experiencia documentada y establecer qué información adicional debe verificarse antes de decidir participar. Evaluar esta priorización resulta necesario para determinar si la incorporación de señales semánticas y atributos aporta mejoras frente a la recuperación léxica.

La literatura ofrece distintas soluciones para aprovechar la información contractual. Nai et al. (2023) integraron datos de contratación y resoluciones administrativas de Italia, y desarrollaron componentes para recuperar contrataciones similares y recomendar empresas a partir de los requisitos de un proceso. Siciliani et al. (2023) propusieron un sistema de apoyo a la decisión que reúne búsqueda semántica, resumen, extracción de información y exploración de datos estructurados y textuales. Ambos trabajos muestran la utilidad del procesamiento de lenguaje natural para consultar y analizar información de contratación, aunque sus tareas no equivalen a evaluar un ranking de oportunidades posteriores para una empresa representada mediante sus adjudicaciones previas.

Desde la perspectiva del descubrimiento de proveedores, Papa et al. (2024) combinaron técnicas de procesamiento de lenguaje natural y desambiguación de entidades para identificar empresas mediante Reddit y Wikidata, con una aplicación al sector financiero. Su propuesta apoya la identificación de proveedores antes de su selección, en lugar de recuperar convocatorias para un proveedor con historial contractual. Más directamente relacionado con esta última tarea, Tikshaev y Sidorov (2026) presentaron una cascada de agentes para evaluar la relevancia de procedimientos del entorno Tenders Electronic Daily respecto de un perfil empresarial, incorporando restricciones y evidencias explicativas. Este antecedente muestra que la vinculación entre oportunidades y perfiles ya ha sido abordada en la literatura.

En conjunto, estos estudios proporcionan soluciones de recuperación, análisis documental y vinculación con proveedores, pero no resuelven la pregunta específica planteada en esta investigación: cuál es el aporte de combinar señales léxicas, semánticas y atributos observables en una evaluación retrospectiva de servicios peruanos, con perfiles reconstruidos a partir de adjudicaciones anteriores. El vacío delimitado en los trabajos revisados es la falta de evidencia comparativa bajo esas condiciones de representación, datos y evaluación. Esta limitación adquiere relevancia cuando existen atributos incompletos y las adjudicaciones solo permiten identificar positivos observados: una oportunidad no adjudicada a una empresa no constituye necesariamente un caso incompatible.

El objetivo de este trabajo es implementar y evaluar una prueba de concepto reproducible de recomendación de oportunidades de contratación pública de servicios para empresas en el Perú, mediante procesamiento de lenguaje natural y un modelo híbrido que combine recuperación léxica, similitud semántica y atributos estructurados. La contribución del artículo consiste en proponer un procedimiento reproducible de construcción de perfiles empresariales históricos y comparación de cuatro configuraciones de recuperación sobre oportunidades de servicios peruanos. Este procedimiento permite examinar el aporte de las señales léxicas, semánticas y estructuradas, delimitando la interpretación de los resultados ante atributos incompletos y etiquetas de adjudicación observadas.

Para ello, se plantea una metodología de cinco etapas: definición de variables y del protocolo de evaluación; construcción del corpus y de los perfiles empresariales; procesamiento textual y representación semántica; integración del ranking y sus explicaciones; y evaluación comparativa. Se utilizarán registros públicos de contratación en formato OCDS, BM25 como referencia léxica y LaBSE preentrenado para la representación semántica. Las configuraciones se contrastarán sobre perfiles y candidatos comunes mediante Precision@k, Recall@k y F1@k, junto con un análisis de errores y de las limitaciones de los datos. La separación temporal entre antecedentes y oportunidades permitirá examinar la recuperación posterior sin interpretar los puntajes como probabilidades de adjudicación.

La investigación se orienta por las siguientes preguntas: PI1: ¿cómo cambia la recuperación de adjudicaciones observadas al combinar BM25 y LaBSE, frente a utilizar cada componente por separado? PI2: ¿qué variación produce añadir atributos estructurados a la combinación léxico-semántica? PI3: ¿qué limitaciones presentan los resultados ante la disponibilidad desigual de atributos y el carácter incompleto de las etiquetas de adjudicación? Estas preguntas distinguen el desempeño del ranking de la elegibilidad integral de una empresa para participar.

El resto del artículo se organiza de la siguiente manera. La sección 2 presenta y compara los trabajos relacionados. La sección 3 desarrolla los fundamentos teóricos de la recuperación léxica, la representación semántica y la evaluación de recomendaciones. Finalmente, la sección 4 describe las cinco etapas de la metodología propuesta.

2. TRABAJOS RELACIONADOS

Los estudios sobre procesamiento de lenguaje natural y recomendación en contratación pública abordan distintas decisiones. Algunos permiten interpretar documentos o recuperar procesos similares. Otros identifican proveedores o valoran oportunidades según un perfil empresarial. Para comparar estos enfoques, se revisaron sus fuentes de datos, la forma de representar a la empresa y la evidencia utilizada para evaluar los resultados.

La revisión se actualizó el 11 de octubre de 2026 mediante búsquedas web de publicaciones científicas y consultas a páginas editoriales y repositorios institucionales. Se emplearon tres cadenas de búsqueda. La primera fue ("public procurement" OR "public tender") AND ("natural language processing" OR "semantic search" OR "recommender system"). La segunda fue ("supplier discovery" OR "contractor recommendation") AND ("natural language processing" OR "historical" OR "network"). La tercera fue "personalized retrieval" AND "knowledge graphs". También se buscaron títulos, autores y DOI para verificar los antecedentes identificados previamente. Se consultaron ScienceDirect, Wiley Online Library, Sage Journals, MDPI e ITcon, junto con los repositorios de las universidades de Torino, Bari y Milano-Bicocca. Este procedimiento corresponde a la actualización de la revisión y no reconstruye la búsqueda inicial.

Se incluyeron artículos originales publicados entre 2023 y el 11 de octubre de 2026 que abordaran el procesamiento de documentos contractuales, la identificación o representación de proveedores, la recuperación personalizada o la relevancia de oportunidades para una empresa. La selección requirió información verificable sobre los datos, el método y la evaluación. Se excluyeron duplicados, trabajos ajenos a estas tareas y versiones preliminares cuando estaba disponible el artículo publicado. El conjunto analizado comprende ocho estudios: Nai et al. (2023), Siciliani

et al. (2023), Papa et al. (2024), Locatelli et al. (2024), Mostofi et al. (2025), Kasela et al. (2025), Peppes et al. (2026) y Tikshaev y Sidorov (2026). La selección es focalizada y no pretende cubrir toda la literatura del área.

Los estudios se organizaron en tres grupos según su propósito principal: procesamiento documental y recuperación en contratación pública, representación de proveedores y personalización, y evaluación explicable de relevancia para la empresa. Esta clasificación permite comparar funciones que pueden coexistir en un mismo sistema. En cada grupo se examinan las coincidencias y diferencias entre los datos utilizados, los resultados obtenidos y el alcance de su validación.

2.1 Procesamiento documental y recuperación en contratación pública

Nai et al. (2023) y Siciliani et al. (2023) utilizan información pública estructurada y textual para apoyar decisiones de contratación. La diferencia está en el resultado que ofrecen. Nai et al. integran la recuperación de contrataciones similares y la recomendación de empresas. Siciliani et al. reúnen búsqueda semántica, resumen, extracción de información y exploración de datos. Aunque ambos aprovechan el contenido contractual, consultar documentos y recuperar procesos semejantes no equivale a ordenar oportunidades posteriores para una empresa.

Locatelli et al. (2024) y Peppes et al. (2026) muestran cómo la definición de las etiquetas cambia la interpretación de los resultados. ArchiBERTo clasifica enunciados de documentos de diseño y organiza sus objetivos. El estudio de Peppes et al. vincula documentación técnica con resultados estructurados para comparar BERT, RoBERTa y DeBERTa en detección de indicadores de riesgo. Ambos interpretan texto contractual, pero evalúan fenómenos diferentes. La concordancia en prioridades de diseño no mide la capacidad de detectar riesgos, y ninguna de estas tareas establece directamente la pertinencia de una convocatoria para un proveedor.

Las evaluaciones reflejan esa diferencia. Locatelli et al. (2024) comparan rankings mediante Kendall τ con el juicio colectivo de tres expertos sobre dos documentos que no se utilizaron para construir los conjuntos de entrenamiento y validación. El resultado favorable de ArchiBERTo en el primer documento respalda su concordancia en ese caso. Peppes et al. (2026) evalúan clasificación mediante precisión, recall, F1 y ROC-AUC, y utilizan Integrated Gradients para analizar las predicciones. Siciliani et al. (2023) incorporan una evaluación de percepciones de uso. En el análisis específico de sus indicadores de colusión participan once responsables de contratación. Así, los estudios aportan evidencia sobre concordancia, discriminación de riesgo y utilidad percibida, sin que estas medidas sean intercambiables.

En este grupo se observa un uso conjunto del texto y los datos estructurados para hacer consultable e interpretable la documentación. Su principal fortaleza es aprovechar información que una búsqueda por campos administrativos podría omitir. Para la propuesta, el límite está en la referencia de evaluación. Los objetivos de diseño, los indicadores de riesgo y las percepciones de uso responden a preguntas distintas de la recuperación de oportunidades para una empresa según las tareas evaluadas por Nai et al. (2023), Siciliani et al. (2023), Locatelli et al. (2024) y Peppes et al. (2026). Por ello, la evaluación del ranking debe distinguirse de la calidad del procesamiento documental y de la aceptación del sistema.

2.2 Representación de proveedores y personalización

Papa et al. (2024) y Mostofi et al. (2025) apoyan decisiones sobre proveedores a partir de fuentes diferentes. Papa et al. emplean información comunitaria y desambiguación de entidades para identificar empresas. Mostofi et al. construyen una red de actividades y contratistas con embeddings node2vec e indicadores de desempeño en costos y plazos. El primer enfoque busca descubrir proveedores, mientras el segundo utiliza evidencia de ejecución para recomendar contratistas. Un historial de adjudicaciones puede registrar experiencia, pero no sustituye esos indicadores de desempeño.

Los resultados de Mostofi et al. (2025) y Kasela et al. (2025) permiten precisar el alcance de la personalización. Mostofi et al. reportan exactitudes de predicción de 88,16 % y 84,08 % para las redes de desempeño en costos y plazos. PARK evalúa recuperación personalizada en cuatro dominios académicos y supera a los modelos comparados en tres, con una mejora de hasta 10 % en MAP@100 respecto del segundo mejor modelo. Estas cifras miden tareas diferentes y no permiten decidir qué sistema recomienda mejor. Las primeras corresponden a predicción sobre redes de desempeño. MAP@100 mide la calidad del ordenamiento de documentos relevantes.

PARK combina BM25, representación densa y una señal del usuario derivada de grafos de conocimiento. Su resultado muestra que la ganancia depende del dominio evaluado (Kasela et al., 2025). Esta observación es relevante para la tesis porque impide asumir que incorporar más información del perfil mejorará siempre la recuperación. El aporte de cada señal debe comprobarse sobre los mismos candidatos y con una referencia común.

La tendencia del grupo es enriquecer los perfiles con historial y relaciones, además del contenido textual. Su utilidad depende de qué representa cada fuente. Papa et al. (2024) observan identidad empresarial, Mostofi et al. (2025) utilizan desempeño y Kasela et al. (2025) representan intereses y relaciones bibliográficas. Para la tesis, esta diferencia limita la transferencia de los métodos. Se necesita evaluar cuánto aporta la experiencia registrada en adjudicaciones sin atribuirle capacidades actuales o calidad de ejecución que los datos no acreditan.

2.3 Evaluación explicable de relevancia para la empresa

Tikshaev y Sidorov (2026) relacionan procedimientos TED con un perfil de proveedor, restricciones y evidencias mediante una cascada de agentes. Frente a los componentes de recuperación de Nai et al. (2023), amplían el análisis hacia condiciones de participación y documentación contractual. Ambos apoyan la selección de alternativas, pero la valoración integrada exige información adicional a la similitud textual. Esto resulta especialmente relevante cuando una oportunidad comparte el tema de actividad de la empresa, pero contiene condiciones que deben verificarse antes de participar.

La comparación con PARK distingue eficacia del ranking y funcionamiento del sistema. Kasela et al. (2025) comparan modelos con métricas de recuperación en varios dominios. Tikshaev y Sidorov (2026) procesan 1563 procedimientos TED y muestran que el prototipo genera resultados explicables. Los autores no presentan esa ejecución como prueba de exactitud del ranking, superioridad frente a métodos simples o generalización. El volumen procesado describe el alcance operativo del caso, pero no reemplaza una referencia de relevancia.

En este enfoque, las restricciones y las evidencias del proveedor adquieren mayor peso en la valoración. La trazabilidad permite examinar los fundamentos de una recomendación, aunque no demuestra por sí sola que el ordenamiento sea eficaz (Tikshaev y Sidorov, 2026). La propuesta recoge esta necesidad mediante explicaciones por componente y una comparación de rankings bajo condiciones comunes. La explicación del puntaje facilitará su revisión, sin presentarse como una certificación de elegibilidad.

2.4 Síntesis crítica, vacíos y posicionamiento de la propuesta

La revisión permite reconocer tres tendencias. Se combina texto contractual con atributos estructurados, se incorporan antecedentes y relaciones en los perfiles, y se busca explicar las valoraciones producidas. Estas tendencias aparecen con diferentes alcances en los estudios de Siciliani et al. (2023), Peppes et al. (2026), Mostofi et al. (2025), Kasela et al. (2025) y Tikshaev y Sidorov (2026). Su desarrollo permite considerar más información, pero también exige precisar qué datos sustentan cada señal y qué aspecto valida cada evaluación.

Los resultados revisados cuestionan la idea de que un sistema más complejo necesariamente obtiene mejores recomendaciones. PARK mejora en tres de cuatro dominios, por lo que su ganancia no es uniforme (Kasela et al., 2025). La cascada de Tikshaev y Sidorov (2026) incorpora restricciones y explicaciones, pero su evaluación no demuestra superioridad del ranking. Estas observaciones señalan límites a la interpretación de los avances técnicos. No constituyen resultados contradictorios entre artículos, pues las tareas, los datos y las referencias de evaluación son distintos.

Las fortalezas del conjunto son el análisis contextual del texto, la representación de perfiles y la posibilidad de revisar las evidencias de una valoración. Sus limitaciones para esta tesis son la dependencia de fuentes diferentes del historial disponible y la diversidad de criterios de evaluación. La concordancia con expertos, la exactitud predictiva, MAP@100 y las percepciones de uso responden a preguntas propias de cada estudio. Comparar sus valores como si midieran una misma calidad de recomendación produciría conclusiones injustificadas al contrastar las evaluaciones de Siciliani et al. (2023), Locatelli et al. (2024), Mostofi et al. (2025) y Kasela et al. (2025).

El vacío identificado en el conjunto revisado es la falta de evidencia directamente aplicable sobre el aporte de las señales léxicas, semánticas y estructuradas cuando los perfiles se construyen con adjudicaciones anteriores y se recuperan oportunidades posteriores de servicios peruanos. Las tareas y representaciones de Nai et al. (2023), Papa et al. (2024), Mostofi et al. (2025) y Kasela et al. (2025) corresponden a otros escenarios. Además, se requiere

examinar cómo los atributos incompletos y las etiquetas de adjudicación limitan esa evaluación. La recuperación histórica ofrece una referencia observable, aunque no cubre las restricciones empresariales consideradas por Tikshaev y Sidorov (2026). La brecha se deriva de esta comparación y se acota a los estudios analizados.

El objetivo de este trabajo es implementar y evaluar una prueba de concepto reproducible que compare BM25, LaBSE, su combinación y la incorporación de atributos estructurados sobre perfiles y candidatos comunes. Los perfiles se construirán con antecedentes anteriores al período evaluado. Las cuatro configuraciones permitirán medir el aporte de las señales y el análisis de errores mostrará las limitaciones de los datos y las etiquetas. La contribución consiste en aportar evidencia comparativa de recuperación de adjudicaciones observadas. La ausencia de adjudicación no se tratará como incompatibilidad confirmada y las recomendaciones requerirán la revisión técnica y legal de cada convocatoria.

3. MARCO TEÓRICO

El marco teórico establece la relación entre los antecedentes de una empresa, la información de las oportunidades y los métodos empleados para compararlos. La recuperación léxica permite identificar coincidencias de términos. Las representaciones semánticas permiten comparar descripciones con vocabulario diferente y los atributos estructurados aportan información adicional sobre los servicios registrados. Estos conceptos sustentan el ranking propuesto y definen qué puede medirse con los datos disponibles.

3.1 Contratación pública y oportunidades de servicios

La contratación pública genera registros de las convocatorias, adjudicaciones y contratos, además de documentos que describen las necesidades de las entidades y las condiciones de participación. Los campos estructurados facilitan la comparación de fechas, categorías, montos e identificadores. El contenido documental permite examinar el objeto del servicio y sus requisitos. La integración de ambas fuentes es la base de las herramientas de análisis y recuperación descritas por Siciliani et al. (2023) y Nai et al. (2023).

En esta investigación, una oportunidad es un proceso de contratación de servicios publicado y representado mediante la información accesible en su registro y sus documentos. El título, la descripción, la categoría, el monto y la ubicación aportan evidencias diferentes. Su disponibilidad no garantiza que se hayan identificado todos los requisitos técnicos. La experiencia requerida solo puede incorporarse cuando exista información que permita reconocerla y atribuirla correctamente al proveedor.

El estándar Open Contracting Data Standard (OCDS) organiza información sobre las etapas de un proceso y sus actualizaciones. Una publicación individual, denominada release, conserva información registrada o publicada en un momento determinado. La documentación de Open Contracting Partnership (s. f.) distingue estas publicaciones de los registros que integran sus cambios. Por eso, un registro consolidado puede contener datos incorporados después de la convocatoria inicial.

La separación temporal requiere comprobar cuándo estaba disponible la información, además de la fecha de adjudicación. Para representar el conocimiento previo de una empresa, sus antecedentes deben proceder de versiones publicadas antes del corte de evaluación. Este criterio reduce el riesgo de utilizar información futura. Una vez delimitadas las oportunidades y las fuentes admisibles, se necesita definir cómo esos antecedentes representan a la empresa.

3.2 Perfil empresarial y compatibilidad

El perfil empresarial reúne evidencia observable de adjudicaciones anteriores, como servicios, descripciones, categorías, regiones y montos. Representa experiencia registrada durante un período, sin describir necesariamente todas las capacidades actuales de la empresa. Esta diferencia es relevante porque los modelos basados en desempeño utilizan información adicional sobre ejecución, costos y plazos, como ocurre en Mostofi et al. (2025).

La compatibilidad se entiende como una relación entre una empresa y una oportunidad. En este trabajo se aproxima mediante afinidad textual y coincidencias estructuradas. La categoría, la región y el monto describen antecedentes

comparables cuando sus valores son utilizables. Sin embargo, una coincidencia regional no acredita capacidad de atender el lugar de ejecución y un monto adjudicado no demuestra disponibilidad financiera. La valoración integral de participación requiere restricciones y evidencias adicionales, como muestran Tikshaev y Sidorov (2026).

El modelo híbrido expresa esta aproximación mediante una combinación ponderada:

$C(p,o) = \alpha L(p,o) + \beta S(p,o) + \gamma A(p,o)$, con $\alpha, \beta, \gamma \geq 0$ y $\alpha + \beta + \gamma = 1$.

En esta expresión, p es el perfil empresarial y o la oportunidad. L es la señal léxica, S la señal semántica y A reúne las afinidades estructuradas. Los pesos determinan la contribución relativa de cada componente. Para combinarlos, deben definirse escalas comparables y reglas para los valores ausentes. El puntaje resultante permite ordenar candidatos, pero no está calibrado como probabilidad de adjudicación. La combinación de señales de contenido y perfil también aparece en PARK, aunque con una representación del usuario distinta (Kasela et al., 2025).

La explicación del puntaje debe mostrar cuánto aporta cada señal y qué información la respalda. Una característica ausente debe distinguirse de una discrepancia observada. Esta definición del perfil y sus límites permite formular la tarea de recuperación: encontrar y ordenar oportunidades relacionadas con la evidencia histórica de la empresa.

3.3 Recuperación de información

La recuperación de información estudia cómo localizar documentos relevantes para una necesidad de información dentro de una colección. En el sistema propuesto, el perfil textual actúa como consulta y las oportunidades forman la colección candidata. La relevancia depende de la tarea y de la referencia utilizada para evaluarla, según Manning et al. (2008). Por ello, la similitud con el historial constituye una señal de recuperación que debe contrastarse con evidencias observadas.

BM25 es un modelo de recuperación léxica fundamentado en el marco probabilístico de relevancia (Robertson y Zaragoza, 2009). Su puntuación combina la frecuencia de un término en el documento, su rareza en la colección y un ajuste por longitud. La saturación reduce la ganancia marginal de repetir una palabra. La normalización por longitud controla la ventaja que podría obtener un texto extenso por contener más términos. La forma utilizada en este trabajo se expresa como:

$$BM25(d,q) = \Sigma_{t \in q}\ IDF(t) \times f(t,d)(k_1 + 1) / [f(t,d) + k_1(1 - b + b|d|/avgdl)].$$

d representa el documento y q la consulta. f(t,d) es la frecuencia del término t en d, |d| su longitud en tokens y avgdl la longitud media de los documentos. El parámetro k_1 controla la saturación de frecuencia y b el ajuste por longitud. La suma incorpora las contribuciones de los términos de la consulta. En la implementación, IDF se calcula con la siguiente variante:

$$IDF(t) = \ln[1 + (N - df(t) + 0{,}5)/(df(t) + 0{,}5)].$$

N es el número de documentos y df(t) la cantidad de documentos que contienen el término. Los puntajes dependen de la consulta y de las estadísticas de la colección. Antes de fusionarlos con la señal semántica se utiliza una transformación min–max, $x' = (x - \text{mínimo})/(\text{máximo} - \text{mínimo})$, cuando existe variación. Si todos los valores son iguales, se requiere una regla explícita para ese caso. Esta transformación ajusta la escala, pero no convierte el puntaje en una probabilidad ni permite compararlo directamente entre consultas.

BM25 aporta una referencia interpretable basada en coincidencias de términos. Su limitación es que no modela por sí mismo equivalencias entre expresiones diferentes. La comparación con representaciones semánticas permite examinar ese aspecto sin asumir que el modelo neuronal siempre será superior. Ambos métodos requieren preparar los textos de acuerdo con su forma de procesamiento, lo que conduce al papel del lenguaje natural en el sistema.

3.4 Procesamiento de lenguaje natural

El procesamiento de lenguaje natural permite convertir texto en representaciones que un sistema computacional puede analizar. En esta investigación cumple tres funciones: preparar el contenido, identificar información y producir representaciones para comparar perfiles y oportunidades. La extracción identifica campos o fragmentos, mientras la representación transforma el contenido en términos o vectores. Estas operaciones requieren evaluaciones distintas, aunque sus errores pueden afectar el mismo ranking.

El preprocesamiento debe respetar las necesidades del modelo. BM25 utiliza tokens para contar coincidencias y estimar estadísticas de la colección. En LaBSE, el tokenizador propio transforma el texto en las unidades utilizadas por el codificador. Una limpieza excesiva puede eliminar contexto útil para la representación semántica. Conservar el texto fuente y registrar las transformaciones permite revisar cómo se produjo cada entrada.

La extracción documental tampoco es equivalente a copiar campos de un registro estructurado. Identificar experiencia requerida en un documento exige distinguir requisitos de la empresa, del personal o de otros elementos del servicio. Cuando se aplica reconocimiento óptico de caracteres (OCR), sus errores pueden modificar cifras y expresiones relevantes. La ausencia de un valor debe conservarse como información desconocida si la fuente no permite verificarlo. Nai et al. (2023) y Siciliani et al. (2024) muestran aplicaciones de análisis y extracción sobre información administrativa y contractual.

El procesamiento produce textos y campos con procedencia identificable. Su función es conservar información útil para las comparaciones posteriores, además de corregir diferencias de formato. Esta preparación permite pasar de coincidencias de palabras a representaciones que capturan relaciones semánticas entre las descripciones.

3.5 Representaciones semánticas basadas en BERT

BERT utiliza un codificador Transformer para generar representaciones contextuales. Mediante mecanismos de atención, la representación de un token incorpora información de otros tokens de la secuencia. Su preentrenamiento bidireccional permite adaptar los parámetros a distintas tareas de lenguaje (Devlin et al., 2019). Sin embargo, el modelo original no fue diseñado específicamente para producir embeddings de oraciones cuya distancia represente similitud semántica.

Sentence-BERT adapta BERT mediante estructuras siamesas y tripletas para obtener vectores de oraciones comparables. Los codificadores comparten parámetros y permiten representar los textos de forma independiente, lo que facilita su comparación mediante coseno (Reimers y Gurevych, 2019). LaBSE utiliza objetivos de preentrenamiento y aprendizaje sobre pares de traducción para alinear oraciones de diferentes idiomas en un espacio vectorial común (Feng et al., 2022).

BERT, Sentence-BERT y LaBSE designan modelos o enfoques diferentes. Sentence-Transformers es la biblioteca utilizada para ejecutar LaBSE en este estudio, cuyo identificador es sentence-transformers/LaBSE. El carácter multilingüe facilita representar textos en español, aunque su eficacia sobre servicios peruanos debe evaluarse con el corpus del trabajo.

La similitud coseno compara la dirección de dos vectores no nulos y se define como:

$\cos(p,o) = (v\square \cdot v_o) / (\|v\square\| \|v_o\|)$.

$v\square$ y v_o representan el perfil y la oportunidad. El resultado se encuentra entre −1 y 1. Un valor alto indica cercanía entre sus representaciones, sin acreditar el cumplimiento de requisitos. La construcción del texto y la agregación de varios antecedentes afectan el vector del perfil. Cuando se procesan fragmentos, la regla para combinarlos debe documentarse porque puede cambiar la importancia de cada especialidad.

La representación semántica permite examinar relaciones que una coincidencia léxica podría omitir. Su combinación con BM25 y los atributos estructurados requiere medir el aporte de cada señal sobre las mismas entradas. La similitud coseno interviene en el cálculo del ranking, mientras que la calidad de las recomendaciones debe establecerse mediante métricas de evaluación.

3.6 Métricas de evaluación

La evaluación debe corresponder a la tarea y a una referencia definida. En extracción, un verdadero positivo es un valor correctamente identificado según las reglas de comparación. Un falso positivo es una extracción incorrecta y un falso negativo es un valor de referencia que no se recuperó. Precisión (P) y recall (R) se calculan como $P = TP/(TP + FP)$ y $R = TP/(TP + FN)$. Su media armónica es:

$F1 = 2PR/(P + R)$.

F1 se define como cero cuando P y R son cero. Para evaluar campos se necesita una referencia verificable y un criterio de coincidencia, que puede exigir igualdad exacta o admitir una normalización documentada. Los casos

cuya fuente no permite determinar el valor deben informarse como no evaluables. La concordancia con un registro estructurado comprueba la transformación respecto de ese registro, pero no demuestra una extracción correcta de todos los requisitos documentales.

En recuperación se evalúa el conjunto de las primeras k recomendaciones, siguiendo el enfoque descrito por Manning et al. (2008). Para un perfil p, R(p) es el conjunto de positivos observados y TP□(k) es el número de esos positivos recuperados en las primeras k posiciones:

Precision@k = TP□(k)/k.

Recall@k = TP□(k)/|R(p)|.

F1@k = 2 × Precision@k × Recall@k / (Precision@k + Recall@k).

El estudio utiliza k = 5 y k = 10. Cada métrica se calcula por perfil y después se obtiene su promedio no ponderado, de modo que cada perfil evaluable aporta el mismo peso. F1@k se promedia a partir de los valores individuales y no se calcula sobre los promedios de precisión y recall. Si un perfil carece de positivos conocidos, Recall@k no está definido para esa referencia y su cobertura debe informarse por separado.

Las adjudicaciones posteriores pueden utilizarse como positivos en una evaluación retrospectiva, siempre que no intervengan en los perfiles ni en las características disponibles antes de la oportunidad. La ausencia de adjudicación no demuestra incompatibilidad. Por eso, las métricas del trabajo describen recuperación de positivos observados y no una evaluación exhaustiva de pertinencia empresarial. Precision@k, Recall@k y F1@k tampoco distinguen permutaciones dentro de las primeras k posiciones. El análisis de errores permite examinar aspectos que sus promedios no muestran.

Estas métricas completan la relación entre datos, representación y ordenamiento. Los antecedentes delimitan la evidencia empresarial, el procesamiento prepara sus textos y BM25 y LaBSE generan señales complementarias. Los atributos estructurados añaden afinidades observables al puntaje. La evaluación determina qué aporta esa combinación dentro de una referencia explícita y el análisis de errores permite interpretar sus límites. Sobre esta base, la metodología siguiente define el corpus, las transformaciones y las comparaciones necesarias para evaluar la propuesta.

4. METODOLOGÍA

La investigación adopta un enfoque cuantitativo, con una evaluación computacional retrospectiva de alcance exploratorio. Se comparan métodos de recuperación sobre los mismos perfiles empresariales y oportunidades de contratación pública de servicios. El estudio utiliza registros históricos y no interviene en los procesos de contratación. Las adjudicaciones observadas constituyen la referencia de evaluación, por lo que el desempeño obtenido describe su recuperación y no la elegibilidad integral ni la probabilidad de adjudicación de una empresa.

La metodología se organiza en cinco etapas vinculadas con los objetivos específicos. Primero se definen las variables y el protocolo de evaluación. Después se construyen el corpus y los perfiles empresariales, y se preparan sus representaciones textuales. La cuarta etapa integra las señales para generar recomendaciones explicables. Finalmente, se comparan los métodos y se analizan los resultados. La Figura 1 muestra la secuencia de etapas y sus actividades principales.

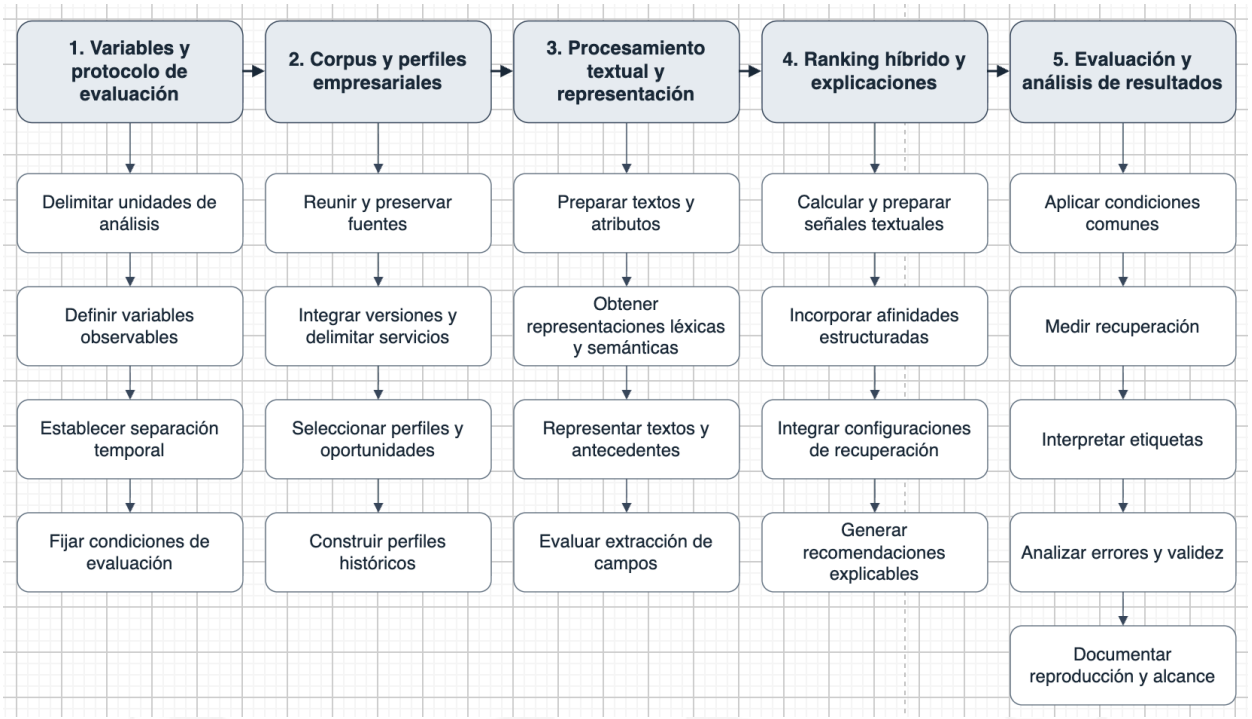


Figura 1. Flujo de etapas y actividades de la metodología. Elaboración propia.

4.1 Etapa 1. Definición de variables y protocolo de evaluación

Esta etapa tiene como objetivo delimitar qué se evaluará, qué evidencia se utilizará y bajo qué condiciones se compararán los métodos. Su resultado es un protocolo común que orienta la construcción de los datos y la interpretación de los indicadores.

Actividad 1. Delimitar las unidades de análisis. Su propósito es establecer la relación que evaluará el sistema. Se define la oportunidad como un proceso de contratación de servicios publicado, el perfil como una representación de antecedentes empresariales y el par empresa–oportunidad como la unidad que recibe una puntuación.

Actividad 2. Definir las variables observables. Se busca identificar la información que puede sustentar la comparación entre perfiles y oportunidades. Se consideran el objeto, las descripciones, la categoría, la región, el monto y las fechas, junto con sus identificadores y fuentes. Los requisitos adicionales solo se incorporan cuando existe evidencia verificable. Se distingue la ausencia de información de una discrepancia observada.

Actividad 3. Establecer la separación temporal. El objetivo es utilizar únicamente evidencia disponible antes del período evaluado para representar a las empresas. Se separan los antecedentes históricos, las características de las oportunidades y las adjudicaciones posteriores empleadas como etiquetas. La verificación debe considerar cuándo se publicó cada dato, además de la fecha del evento contractual.

Actividad 4. Fijar las condiciones de evaluación. Su finalidad es definir la población de interés, los criterios de selección y las métricas antes de interpretar los resultados. El contraste anual utiliza empresas distintas de las empleadas en desarrollo y las selecciona por su historial, sin exigir adjudicaciones posteriores. Los candidatos se fijan antes de consultar sus desenlaces y no se incorporan oportunidades por ser positivas. El protocolo conserva las decisiones y sus versiones para revisar cualquier cambio.

El diseño distingue dos evaluaciones. La primera compara la recuperación retrospectiva sobre la colección anual de 2025. La segunda examina por separado la extracción documental de experiencia con una referencia automática. Esta última continúa en preparación y sus predicciones solo se contrastarán después de cerrar la referencia. Las especificaciones de datos, formalización y reproducción se presentan en la sección 4.6.

Con las unidades, variables y condiciones definidas, la siguiente etapa reúne las fuentes y construye el conjunto sobre el que se realizarán las comparaciones.

4.2 Etapa 2. Construcción del corpus y de los perfiles empresariales

El objetivo de esta etapa es organizar un corpus trazable de oportunidades de servicios y antecedentes empresariales. Se busca que cada elemento conserve su procedencia y pueda relacionarse con el período al que pertenece.

Actividad 1. Reunir y preservar las fuentes. Su propósito es disponer de registros y documentos que respalden los datos utilizados. Se emplean datos abiertos de contratación de OECE en formato OCDS y documentación complementaria accesible mediante SEACE. Las fuentes originales se conservan para permitir su consulta y la verificación de los valores obtenidos.

Actividad 2. Integrar versiones y delimitar los servicios. Esta actividad busca reconstruir los procesos sin confundir actualizaciones posteriores con información disponible al inicio. Se vinculan sus publicaciones, se identifica el objeto de contratación y se separan los registros de servicios que cumplen los criterios del estudio. La información destinada al ranking se distingue de los resultados contractuales utilizados para evaluar.

Actividad 3. Seleccionar perfiles y oportunidades. El objetivo es formar un conjunto común sin condicionar su selección a adjudicaciones futuras. Se preseleccionan empresas según su cantidad de antecedentes y se verifica la disponibilidad histórica de sus fuentes. Se conserva la colección anual de servicios que supera los controles de publicación. Las exclusiones se documentan y no se reemplazan empresas ni candidatos para aumentar los positivos observados.

Actividad 4. Construir los perfiles históricos. Su finalidad es reunir los antecedentes admisibles de cada empresa y conservar su relación con las fuentes. Los perfiles integran descripciones y atributos observables anteriores al corte de evaluación. Se registran las fechas, los enlaces de origen y las limitaciones de disponibilidad para que la experiencia representada pueda revisarse.

El corpus procede de 48 snapshots mensuales de OECE correspondientes a 2022–2025. De 50 empresas preseleccionadas se retienen 49 con al menos dos antecedentes verificables anteriores al 1 de enero de 2025, que reúnen 210 adjudicaciones. De 34 485 oportunidades previstas se conservan 33 584 publicadas durante 2025. Las 901 restantes se excluyen porque su primera versión verificable fue publicada en 2026. La selección, las versiones y los motivos de exclusión se conservan en inventarios identificados.

El corpus resultante proporciona las entradas comunes del experimento. La siguiente etapa prepara sus textos y atributos para generar representaciones comparables.

4.3 Etapa 3. Procesamiento textual y representación semántica

Esta etapa busca transformar el contenido disponible en representaciones útiles para la recuperación, conservando su significado y procedencia. También establece cómo se evaluará la información extraída antes de utilizarla como evidencia del perfil o de la oportunidad.

Actividad 1. Preparar los textos y atributos. El propósito es reducir diferencias de formato que dificulten la comparación. Se organizan títulos, descripciones y fragmentos disponibles, y se mantienen separados los campos estructurados. Los textos del registro se distinguen de los requisitos contenidos en documentos técnicos. Los valores desconocidos se conservan como tales.

Actividad 2. Obtener representaciones léxicas y semánticas. Se busca disponer de dos formas complementarias de comparar el contenido. La representación léxica permite identificar coincidencias de términos mediante BM25. La representación semántica utiliza LaBSE preentrenado para examinar relaciones entre descripciones con vocabulario diferente.

Actividad 3. Representar textos extensos y antecedentes múltiples. Su finalidad es obtener una representación del perfil que reúna su experiencia registrada y respete los límites de procesamiento del modelo. Cuando el contenido requiere fragmentación o agregación, se define una regla común y se documenta su efecto sobre la información representada.

Actividad 4. Evaluar la extracción de campos. El objetivo es comprobar si los valores corresponden a evidencia verificable. Objeto, categoría, región y monto se contrastan con campos de la fuente estructurada. La experiencia requerida se revisa mediante un protocolo documental separado que distingue requisitos del postor, del personal y

factores de evaluación. La referencia de experiencia se construye con dos lecturas de las fuentes, sin consultar predicciones, y debe fijarse antes de calcular las métricas. Los casos ambiguos o inaccesibles se registran como limitaciones de evaluación.

Para experiencia se fijaron 50 oportunidades nuevas, excluyendo procesos y archivos utilizados en desarrollo. Se recuperaron 27 PDF completos, mientras once excedieron el límite de descarga y doce carecían de un enlace elegible. Esos 23 casos permanecen en el denominador de cobertura y no se convierten en negativos. La revisión automática puede compartir errores con el extractor, por lo que sus resultados se interpretarán como concordancia con esa referencia. Los documentos descargados actualmente no acreditan por sí mismos disponibilidad histórica y no se incorporan al ranking anual.

Las representaciones y los campos revisados permiten calcular las señales de comparación. La cuarta etapa define cómo se combinan para producir el orden de las recomendaciones.

4.4 Etapa 4. Integración del ranking híbrido y de sus explicaciones

La cuarta etapa tiene como objetivo ordenar las oportunidades según su afinidad con el perfil empresarial y mostrar las evidencias que sustentan cada puntuación. Se combinan señales léxicas, semánticas y estructuradas bajo reglas comunes.

Actividad 1. Calcular y preparar las señales textuales. Su propósito es medir la coincidencia léxica y la cercanía semántica entre cada perfil y los mismos candidatos. Las señales se llevan a escalas comparables antes de su integración, para que las diferencias de magnitud no determinen por sí solas el peso de un componente.

Actividad 2. Incorporar las afinidades estructuradas. Se busca complementar el contenido textual con información observable de categoría, región y monto. Solo se comparan valores utilizables y, para los importes, monedas identificadas y equivalentes. La ausencia de evidencia se muestra de forma explícita y no se interpreta como incumplimiento de un requisito.

Actividad 3. Integrar las configuraciones de recuperación. El objetivo es obtener rankings que permitan examinar el aporte de cada grupo de señales. Se consideran BM25, LaBSE, su combinación y el híbrido con atributos estructurados. Las reglas de combinación se fijan para la comparación y no se ajustan para obtener una ventaja sobre el conjunto ya evaluado.

El puntaje combina cinco señales, $C(p,o) = wL \cdot L(p,o) + wS \cdot S(p,o) + wG \cdot G(p,o) + wR \cdot R(p,o) + wM \cdot M(p,o)$, con pesos no negativos cuya suma es uno. L y S son las señales textuales normalizadas, y G, R y M representan categoría, región y monto. Las configuraciones conservan los pesos fijados para el contraste. Las alternativas posteriores de categorías y agregación semántica se documentan como análisis de desarrollo y no sustituyen silenciosamente esta comparación.

Actividad 4. Generar recomendaciones explicables. Su finalidad es presentar las oportunidades ordenadas junto con sus fuentes y la contribución de cada componente. La salida permite revisar las razones del puntaje e identificar información que requiere comprobación adicional. Estas explicaciones describen el cálculo del sistema y no certifican elegibilidad legal ni capacidad actual de la empresa.

Los rankings obtenidos constituyen la salida que se contrasta con la referencia histórica. La última etapa determina qué recupera cada configuración y qué límites afectan su interpretación.

4.5 Etapa 5. Evaluación comparativa y análisis de resultados

Esta etapa busca comparar el desempeño de los métodos y determinar el aporte de las señales bajo el protocolo establecido. El análisis incluye los resultados agregados, las diferencias entre perfiles y las amenazas a la validez.

Actividad 1. Aplicar condiciones comunes de comparación. El propósito es atribuir las diferencias observadas a las configuraciones evaluadas y no a cambios en sus entradas. Los métodos utilizan los mismos perfiles, candidatos, referencia de adjudicaciones y corte temporal. La comparación de BM25 con LaBSE y su combinación examina las señales textuales. El contraste con el híbrido permite estudiar después el aporte de los atributos.

La referencia anual contiene 28 pares observados empresa–oportunidad correspondientes a 13 perfiles. Se excluye como positivo un par cuya adjudicación precede a la publicación inicial verificable del texto. La oportunidad y el

perfil permanecen entre las entradas. Los otros 36 perfiles reciben rankings y se informan sin asignarles un Recall artificial. La falta de estado explícito de adjudicación en las fuentes también queda registrada, por lo que la etiqueta representa una relación observada y no certifica vigencia contractual.

Actividad 2. Medir la recuperación. Su objetivo es cuantificar la presencia de positivos observados en las primeras recomendaciones. Se utilizan Precision@k, Recall@k y F1@k para k = 5 y k = 10, con cálculo por perfil y posterior promedio no ponderado. Los perfiles sin positivos conocidos se informan por separado, junto con la cobertura de evaluación.

Para cada perfil p, R(p) reúne sus positivos conocidos y TP□(k) cuenta los recuperados en las primeras k posiciones. Se aplica Precision@k = TP□(k)/k, Recall@k = TP□(k)/|R(p)| y F1@k = 2·Precision@k·Recall@k/(Precision@k + Recall@k). F1@k vale cero cuando ambas medidas son cero. Los promedios se calculan sobre los 13 perfiles evaluables y se informa la cobertura 13/49. La incertidumbre se examina mediante 5000 remuestreos pareados por perfil y un intervalo percentil del 95 %, con semilla 42.

Actividad 3. Delimitar la interpretación de las etiquetas. Se busca mantener las conclusiones dentro de la evidencia disponible. Las adjudicaciones constituyen positivos históricos, mientras que una oportunidad no adjudicada a la empresa conserva una pertinencia desconocida. Los indicadores describen recuperación de casos observados y no toda la compatibilidad empresarial.

Actividad 4. Analizar errores y amenazas a la validez. El objetivo es explicar aciertos, omisiones y diferencias que los promedios podrían ocultar. Se revisan el tipo de servicio, el volumen del historial, los textos insuficientes y los atributos ausentes. La región representa la dirección de la entidad compradora y no un lugar de ejecución verificado. El contraste utiliza el mismo año y la misma fuente ya inspeccionados, por lo que no constituye una prueba temporal completamente ciega ni acredita generalización a convocatorias actuales.

Actividad 5. Documentar la reproducción y el alcance de los resultados. Su finalidad es conservar las entradas, configuraciones y salidas necesarias para repetir la comparación. Se archivan el código, las versiones de datos y modelo, los vectores y sus hashes. Un verificador separado reconstruye puntajes, posiciones y métricas. La reproducción exacta del ranking utiliza el caché archivado, mientras que regenerar embeddings en otro dispositivo constituye una ejecución nueva. La sección 4.6.5 identifica los archivos y la secuencia de reproducción.

4.6 Diseño experimental y protocolo de evaluación

El diseño experimental concreta las decisiones que permiten comparar los métodos y repetir la evaluación. Se especifican los datos, la selección, las representaciones, las configuraciones de ranking y las métricas. La recuperación anual y la extracción documental se mantienen como evaluaciones separadas. Los archivos, manifiestos y comandos identificados al final de este apartado permiten reproducir la corrida desde los artefactos conservados.

4.6.1 Datos, selección y disponibilidad temporal

El corpus fuente comprende 48 snapshots mensuales de 2022–2025. Se excluyen las 50 empresas utilizadas en desarrollo. La población provisional elegible contiene 9672 empresas con al menos dos adjudicaciones anteriores al 1 de enero de 2025. Se estratifica por número de antecedentes: 2–3, 4–7 y 8 o más. Las cuotas proporcionales se asignan por restos mayores y resultan en 31, 13 y 6 empresas. Dentro de cada estrato se ordenan los identificadores por SHA-256 de «20261008:identificador» y se toman los primeros hasta completar la cuota.

La auditoría verifica texto e identidad de adjudicación publicados antes del corte, utilizando release.publishedDate y fechas diarias en America/Lima. Se conserva el identificador de proceso y versión de cada respuesta. Una empresa queda excluida por historial verificable insuficiente y no se reemplaza. La cohorte final contiene 49 empresas y 210 antecedentes. Los candidatos se seleccionan por fecha del proceso en 2025 y se validan por publicación nativa de su versión inicial dentro del mismo año. De 34 485 procesos previstos se conservan 33 584 y se excluyen 901 publicados en 2026.

Las entradas definitivas son historical_awards.csv y test_opportunities.csv, en data/processed/contrast_candidates_v1/annual_v1. La selección está en data/processed/contrast_selection_v1/selection_manifest.json. Las exclusiones y fuentes históricas figuran en

data/processed/contrast_history_validated_v1. Los controles de candidatos están en artifacts/annual_pool_v1/final_input_verification.json. Los metadatos de publicación son evidencia informada por OECE y no una observación independiente del acceso a los endpoints en 2024 o 2025.

4.6.2 Representaciones y configuración del modelo

La consulta léxica reúne el texto de los antecedentes del perfil. Se aplica normalización Unicode NFKD, eliminación de marcas diacríticas, conversión a minúsculas y tokenización de secuencias [a-z0-9]+. BM25 utiliza $k_1 = 1,5$ y $b = 0,75$, con la fórmula e IDF descritas en la sección 3.3. Sus estadísticas se calculan sobre la colección anual común.

La señal semántica utiliza sentence-transformers/LaBSE, revisión 836121a0533e5664b21c7aacc5d22951f2b8b25b, con vectores de 768 dimensiones y normalización L2. El límite es 256 tokens, incluidos los especiales. Los fragmentos admiten hasta 254 tokens de contenido y se verifica el límite después de retokenizar. La enmienda retokenization_checked_v2 conserva todas las posiciones del texto y ajusta límites cuando la retokenización los excede. Se promedian los vectores normalizados de los fragmentos y se normaliza de nuevo el resultado. El perfil se obtiene mediante promedio normalizado de los vectores de sus adjudicaciones.

Las versiones registradas para codificación son Sentence-Transformers 5.7.0, Transformers 5.16.1, PyTorch 2.13.0 y NumPy 2.5.2. El caché documenta la ejecución por bloques, incluidos los bloques anteriores cuyo dispositivo no fue registrado y los posteriores en MPS con lote de ocho. La corrida anual de ranking reutiliza ese caché en CPU. La configuración y los hashes se conservan en artifacts/contrast_embeddings_v1/annual_v1/metadata.json y artifacts/contrast_embedding_amendment_v2/amendment.json.

4.6.3 Formalización del ranking y tratamiento de ausencias

Para cada perfil se normalizan los puntajes léxicos y semánticos sobre sus candidatos mediante min–max. Si mínimo y máximo son numéricamente iguales, la señal vale uno cuando el valor común es positivo y cero en otro caso. G vale uno si la categoría no vacía de la oportunidad coincide con una categoría informativa del historial, después de quitar espacios extremos y convertir a minúsculas. Las categorías genéricas services y consultingservices aportan cero. R vale uno si la región no vacía coincide con alguna región del historial. Esta región procede de la entidad compradora.

Sea m_o el monto positivo y finito de la oportunidad y $m\square$ la mediana de montos históricos positivos y finitos expresados en la misma moneda identificada. La afinidad monetaria es $M(p,o) = \exp(-|\ln(m_o) - \ln(m\square)|)$. No se convierten divisas. Si no existe evidencia comparable, M aporta cero. Los atributos ausentes no redistribuyen los pesos y su contribución nula se informa como falta de evidencia, sin inferir incompatibilidad.

BM25: $C = L$.

LaBSE: $C = S$.

Combinación léxico-semántica: $C = 0,412L + 0,588S$.

Híbrido con atributos: $C = 0,35L + 0,50S + 0,08G + 0,04R + 0,03M$.

Los pesos son decisiones congeladas del contraste, no parámetros óptimos obtenidos mediante ajuste en la prueba. Las oportunidades se ordenan por puntaje descendente y los empates por identificador OCID ascendente. Se conserva el ranking completo y se presentan las primeras diez oportunidades con fuente, señales y contribuciones ponderadas. Las alternativas de códigos o agregación semántica se identifican como experimentos separados.

4.6.4 Etiquetas, métricas y evaluación documental

La etiqueta anual vincula una empresa seleccionada con una adjudicación observada de 2025 posterior al día de publicación inicial verificable del texto. De 29 pares encontrados se retienen 28. Los demás pares siguen sin etiqueta confirmada. Los indicadores de la sección 4.5 se calculan por perfil a $k = 5$ y $k = 10$ y se promedian sobre los 13 perfiles con positivos conocidos. Los 36 restantes se conservan y se informa la cobertura. Los intervalos utilizan 5000 remuestreos pareados por perfil, semilla 42 y percentiles 2,5 y 97,5. Su interpretación es exploratoria.

La evaluación documental de experiencia utiliza una selección separada de 50 oportunidades de un universo de 29 476 candidatas, excluyendo procesos y PDF conocidos de desarrollo. Los OCID se ordenan por SHA-256 de «20261010-experience-holdout-v1:ocid» y se eligen los primeros 50. La descarga se limita a 10 MiB por archivo y

conserva los casos inaccesibles o parciales. La revisión debe confirmar que el alcance sea un servicio empresarial. Obras, consultoría de obra y requisitos del personal se distinguen del requisito del postor.

La referencia automática requiere dos lecturas de las fuentes, respaldo de página y fragmento, registro de discrepancias y cierre antes de confrontar predicciones. La identidad de una condición combina proceso, sujeto, rol de sección, ítem y rama. Los campos evaluados actualmente son monto facturado, moneda y ventana de años. El monto se normaliza a dos decimales sin redondear valores adicionales no nulos, la moneda se compara por código ISO literal y los años se obtienen de evidencia explícita. Una cifra con identidad incorrecta no cuenta como acierto.

Un valor incorrecto suma un falso positivo y un falso negativo. La omisión de un valor conocido suma un falso negativo. Una extracción espuria suma un falso positivo solo si existe referencia documental completa y elegible. Los valores desconocidos se excluyen del cálculo del campo y se informan por separado. Recall y F1 se reportan como no estimables cuando no hay soporte positivo. Se informa cobertura sobre los 50 casos y abstenciones. Las reglas y la extensión se comparan con la misma referencia. Esta evaluación continúa en preparación y no acredita exactitud experta ni mejora del ranking histórico.

4.6.5 Archivos y secuencia de reproducción

La reproducción del ranking utiliza artifacts/contrast_preparation_v1/frozen_plan_with_code.json, la cohorte anual, el caché artifacts/contrast_embeddings_v1/annual_v1 y las etiquetas artifacts/annual_positive_audit_v2. El código archivado y sus hashes figuran en los manifiestos de preparación y ejecución. El entorno debe instalar el proyecto y las dependencias de las versiones registradas. Cada repetición utiliza directorios de salida nuevos.

```
python -m pip install -e '.[semantic,sources]'
```

```
python scripts/audit_annual_positives.py --selection data/processed/contrast_selection_v1
--preparation artifacts/contrast_preparation_v1 --cohort
data/processed/contrast_candidates_v1/annual_v1 --cache
artifacts/contrast_embeddings_v1/annual_v1 --corpus data/processed/oece_2022_2025 --output
artifacts/annual_positive_audit_replay
```

```
python scripts/run_annual_contrast.py --preparation artifacts/contrast_preparation_v1 --cohort
data/processed/contrast_candidates_v1/annual_v1 --cache
artifacts/contrast_embeddings_v1/annual_v1 --labels artifacts/annual_positive_audit_replay
--output artifacts/experiment_annual_replay
```

```
python scripts/verify_annual_contrast.py --experiment artifacts/experiment_annual_replay
--cohort data/processed/contrast_candidates_v1/annual_v1 --cache
artifacts/contrast_embeddings_v1/annual_v1 --labels artifacts/annual_positive_audit_replay
--output artifacts/experiment_annual_replay/verification.json
```

```
python -m tesis_recommender analyze --results artifacts/experiment_annual_replay/results.json
--labels artifacts/annual_positive_audit_replay/labels.csv --awards
data/processed/contrast_candidates_v1/annual_v1/historical_awards.csv --output-dir
artifacts/analysis_annual_replay --resamples 5000 --seed 42
```

El verificador debe confirmar los 49 perfiles, los 33 584 candidatos, los 28 positivos, los 196 rankings completos y las 6 582 464 filas. También reconstruye las 1960 explicaciones y recalcula métricas desde las etiquetas. Los hashes de entradas, código, caché y salidas permiten detectar modificaciones. Repetir el ranking con esos vectores reproduce la corrida archivada, sin equivaler a regenerar LaBSE en otro dispositivo.

La selección documental está en artifacts/experience_holdout_plan_v2/selection.json. Las fuentes y revisiones están identificadas en artifacts/experience_holdout_source_view_v1 y en los registros de lectura con sus manifiestos. El código congelado se identifica en artifacts/experience_holdout_models_lock_v1/model_lock.json y la comparación en docs/experience_field_evaluation_protocol_v1.json. No se ejecuta la comparación de experiencia hasta resolver discrepancias o conservar campos desconocidos y fijar la referencia. Su posterior ejecución debe registrarse como un cierre separado.

La metodología articula la preparación de datos, la representación empresarial y la comparación de rankings sobre entradas comunes. La implementación anual y su evaluación de recuperación están ejecutadas. La evaluación documental de experiencia conserva un cierre separado, condicionado a completar las relecturas, resolver discrepancias y fijar la referencia automática. Esta distinción permite documentar el método completo sin atribuir resultados a actividades todavía en curso.

DECLARACIONES

[La información consignada en estas declaraciones debe ser veraz, completa y verificable. Cualquier falsedad, omisión, ocultamiento de información relevante o incumplimiento de las disposiciones éticas y editoriales aplicables podrá ser considerado una falta y, cuando corresponda, ser derivado al Comité Disciplinario de la Facultad para la evaluación y adopción de las medidas que correspondan, de acuerdo con la normativa institucional vigente]

Aprobación ética

[En esta sección se debe indicar si el estudio fue evaluado y aprobado por un comité de ética en investigación. Cuando corresponda, se debe consignar el nombre de la institución o comité responsable, el código o número de aprobación y la fecha de aprobación, así como señalar que la investigación se desarrolló de acuerdo con los principios éticos aplicables. *Ejemplo: El estudio fue evaluado y aprobado por el Comité de Ética en Investigación de [nombre de la institución], mediante aprobación N.° [código], de fecha [fecha]. La investigación se desarrolló de acuerdo con los principios éticos aplicables a la investigación con seres humanos*].

Consentimiento para participar

[En esta sección se debe indicar si los participantes otorgaron su consentimiento informado antes de participar en el estudio. Cuando corresponda, se debe precisar si el consentimiento fue otorgado por escrito o verbalmente, y señalar que los participantes fueron informados sobre los objetivos, procedimientos y uso de los datos recopilados. *Ejemplo: Los 20 participantes otorgaron su consentimiento informado verbal antes de participar en el estudio. Se les informó sobre los objetivos, procedimientos y uso de los datos recopilados*].

Uso de inteligencia artificial generativa:

[En concordancia con el art. 19 del Reglamento para el Uso Responsable de Herramientas Basadas en Inteligencia Artificial, los autores deben declarar el uso de herramientas basadas en IA, generativas o de asistencia, cuando intervengan en la generación, organización o modificación del manuscrito, así como en el análisis de datos, desarrollo de código, generación de figuras u otros productos de investigación, indicando la herramienta, versión y propósito de uso. En todos los casos, los autores son responsables de la veracidad, exactitud, integridad y originalidad de los resultados y deben revisar y validar los productos obtenidos con estas herramientas antes de su publicación o difusión, conforme al Código de Ética y la normativa sobre integridad científica. Ejemplo: Durante la preparación del manuscrito se utilizó ChatGPT-5.6, para reorganizar determinados fragmentos del estado del arte y marco teórico. Los autores revisaron y validaron el contenido generado y asumen la responsabilidad plena sobre el contenido final del artículo].

Si, se utilizo Sol 5.6/6 y Astra 6 para revision y confirmacion de la concordancia de lo redactado con los objetivos de Seminario I, tambien para recomendar formulas y logicas matematicas con respecto a los modelos.

REFERENCIAS

Alma'aitah, W. Z., Quraan, A., Al-Aswadi, F. N., Alkhawaldeh, R. S., Alazab, M., & Awajan, A. (2024). Integration approaches for heterogeneous big data: A survey. *Cybernetics and Information Technologies, 24*(1), 3-20. https://doi.org/10.2478/cait-2024-0001

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)* (pp. 4171–4186). Association for Computational Linguistics. https://doi.org/10.18653/v1/N19-1423

Feng, F., Yang, Y., Cer, D., Arivazhagan, N., & Wang, W. (2022). Language-agnostic BERT sentence embedding. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* (pp. 878–891). Association for Computational Linguistics. https://doi.org/10.18653/v1/2022.acl-long.62

Kasela, P., Pasi, G., & Perego, R. (2025). PARK: Personalized academic retrieval with knowledge-graphs. *Information Systems, 134*, 102574. https://doi.org/10.1016/j.is.2025.102574

Lima, W. E. M., Da Silva, V. R., Da Silva, J. C., Rabêlo, R. D. A. L., & De Paiva, A. C. (2026). HelBERT: A BERT-based pretraining model for public procurement tasks in Portuguese. *Journal of the Brazilian Computer Society, 32*(1), 145-158. https://doi.org/10.5753/jbcs.2026.5511

Locatelli, M., Tagliabue, L. C., & Di Giuda, G. M. (2024). A multi-label text classifier: Application on an Italian public tender procedure, project ISCOL@. *Journal of Information Technology in Construction, 29*, 864-893. https://doi.org/10.36680/j.itcon.2024.038

Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to information retrieval.* Cambridge University Press. https://nlp.stanford.edu/IR-book/information-retrieval-book.html

Mostofi, F., Tokdemir, O. B., Bahadır, Ü., & Toğan, V. (2025). Performance-driven contractor recommendation system using a weighted activity–contractor network. *Computer-Aided Civil and Infrastructure Engineering, 40*(3), 409–424. https://doi.org/10.1111/mice.13332

Nai, R., Meo, R., Morina, G., & Pasteris, P. (2023). Public tenders, complaints, machine learning and recommender systems: A case study in public administration. *Computer Law & Security Review, 51*, 105887. https://doi.org/10.1016/j.clsr.2023.105887

Open Contracting Partnership. (s. f.). *Release reference.* Open Contracting Data Standard. Recuperado el 11 de octubre de 2026, de https://standard.open-contracting.org/latest/en/schema/reference/

Papa, M., Chatzigiannakis, I., & Anagnostopoulos, A. (2024). Automated natural language processing-based supplier discovery for financial services. *Big Data, 12*(1), 30–48. https://doi.org/10.1089/big.2022.0215

Peppes, N., Alexakis, T., Daskalakis, E., & Adamopoulou, E. (2026). AI-driven corruption risk indicator detection: A comparative evaluation of transformer-based NLP models in unstructured procurement data. *Information, 17*(4), 329. https://doi.org/10.3390/info17040329

Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)* (pp. 3982–3992). Association for Computational Linguistics. https://doi.org/10.18653/v1/D19-1410

Robertson, S., & Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval, 3*(4), 333–389. https://doi.org/10.1561/1500000019

Siciliani, L., Ghizzota, E., Basile, P., & Lops, P. (2024). OIE4PA: Open information extraction for the public administration. *Journal of Intelligent Information Systems, 62*(1), 273-294. https://doi.org/10.1007/s10844-023-00814-z

Siciliani, L., Taccardi, V., Basile, P., Di Ciano, M., & Lops, P. (2023). AI-based decision support system for public procurement. *Information Systems, 119*, 102284. https://doi.org/10.1016/j.is.2023.102284

Tikshaev, I., & Sidorov, A. (2026). An agent cascade for explainable relevance assessment of procurement procedures in the Tenders Electronic Daily environment. *Mathematics, 14*(17), 3125. https://doi.org/10.3390/math14173125

Zhang, Y., Zhu, Y., Zhu, Z., Liu, P., Xie, P., & Wu, C. (2025). A domain-finetuned semantic matching framework based on dynamic masking and contrastive learning for specialized text retrieval. *Electronics, 14*(24), 4882. https://doi.org/10.3390/electronics14244882