FICHA DE INVESTIGACIÓN

1. **Curso**
    - Propuesta de Investigación
2. **Integrantes**
    - Alvarez Dominguez Sebastian Alonso
3. **Asesor**
    - Escobedo Cardenas Edwin Jonathan
4. **Título de la investigación**

    Diseño e implementación de un sistema inteligente de recomendación de oportunidades de contratación pública de servicios basado en procesamiento de lenguaje natural para empresas en el Perú
5. **Áreas y líneas de investigación CIS**
    - **Área**: APLICACIONES EN INTELIGENCIA ARTIFICIAL
    - **Línea**: Procesamiento de Lenguaje Natural
6. **Categorías temáticas, líneas y sublíneas de investigación IDIC**
    - **Categoría temática**: INNOVACIÓN Y TECNOLOGÍA DIGITAL
    - **Línea**: Inteligencia artificial y computación avanzada
    - **Sublínea:** Procesamiento de lenguaje natural
7. **Objetivo de Desarrollo Sostenible (ODS)**

ODS 8: Trabajo Decente y Crecimiento Económico

8. Planteamiento del problema

Los datos abiertos de contratación pública permiten estudiar métodos de recuperación de información y apoyo a la decisión. Nai et al. (2023) analizan contrataciones y reclamos administrativos e incorporan recuperación de procesos similares mediante representaciones semánticas. Este antecedente muestra la utilidad del procesamiento de lenguaje natural en el dominio, aunque recuperar una contratación semejante a otra no equivale a recomendar oportunidades a una empresa.

El acceso digital no elimina el trabajo de revisar convocatorias. Una empresa puede pasar por alto un servicio pertinente si sus antecedentes y el aviso emplean términos distintos. Zhang et al. (2025) estudian ese problema de emparejamiento semántico, mientras que Alma'aitah et al. (2024) describen las dificultades de integrar fuentes heterogéneas. El texto no estructurado añade otra dificultad para el procesamiento automático (Roldan-Baluis et al., 2022). En la contratación pública, estas limitaciones afectan tanto la búsqueda como la interpretación de requisitos técnicos.

Siciliani et al. (2023) integran registros y documentos para apoyar decisiones en contratación pública. Su propuesta muestra cómo convertir información dispersa en componentes de búsqueda y análisis. Sin embargo, el destinatario principal es la entidad pública. Para una empresa que busca servicios compatibles con su trayectoria, sigue siendo necesario definir cómo representar el historial y cómo ordenar oportunidades posteriores.

Papa et al. (2024) estudian el descubrimiento de proveedores mediante procesamiento de lenguaje natural en servicios financieros, una tarea distinta de recomendar oportunidades públicas a partir de la trayectoria de una empresa. La brecha de este trabajo no es que falten sistemas inteligentes. Falta evidencia comparable sobre el aporte de la coincidencia léxica, la representación semántica y los atributos observables cuando el perfil proviene de adjudicaciones previas y se buscan oportunidades posteriores de servicios en el Perú. La pregunta es: ¿qué cambia en la recuperación de oportunidades históricamente adjudicadas al combinar BM25, LaBSE y atributos estructurados, frente a BM25, para empresas con historial en la contratación pública peruana de servicios? El estudio contrastará las variantes sin dar por hecho que la combinación será superior.

9. Objetivos

Objetivo general:

Implementar y evaluar una prueba de concepto reproducible de un sistema inteligente de recomendación de oportunidades de contratación pública de servicios para empresas en el Perú, mediante procesamiento de lenguaje natural y un modelo híbrido de compatibilidad.

Objetivos específicos:

- Analizar y definir las variables observables del perfil empresarial y de las oportunidades de contratación pública de servicios que intervienen en su compatibilidad, así como el protocolo experimental y la separación temporal de los datos.
- Construir un corpus reproducible que integre información estructurada y textual de oportunidades de contratación pública, junto con perfiles empresariales derivados de adjudicaciones históricas.
- Desarrollar un módulo de procesamiento de lenguaje natural para limpiar, normalizar y representar semánticamente los textos de oportunidades y perfiles empresariales mediante LaBSE, implementado con Sentence Transformers.
- Integrar un modelo híbrido de recomendación que combine recuperación léxica mediante BM25, similitud semántica y atributos estructurados para generar rankings explicables de compatibilidad entre empresas y oportunidades.
- Evaluar comparativamente BM25, LaBSE y las combinaciones híbridas mediante Precision@k, Recall@k y F1@k, para k = 5 y 10, y analizar sus errores, el aporte de cada componente y las limitaciones de las etiquetas históricas.

10. Justificación

Participar en contratación pública exige detectar convocatorias pertinentes antes de preparar una oferta. Esta tarea puede ser especialmente costosa para empresas pequeñas que no cuentan con equipos dedicados a revisar procesos. Driel et al. (2026) describen dificultades de las pymes para identificar oportunidades en su estudio del sector defensa. Ese antecedente motiva la aplicación, pero no permite afirmar que el prototipo vaya a aumentar por sí solo la participación o la competitividad de las empresas peruanas.

La justificación tecnológica está en medir qué aporta cada forma de comparación. BM25 representa coincidencias de términos, LaBSE relaciona descripciones con vocabulario diferente y los atributos estructurados recogen afinidades observables. Mentzingen et al. (2024), Oussalah y Mohamed (2022) y Alsaif et al. (2022) ofrecen antecedentes para estas técnicas en otros problemas. Sus resultados no se trasladan automáticamente a servicios públicos peruanos. Aquí se evaluará la recuperación retrospectiva. La utilidad práctica y el tiempo de búsqueda requerirían pruebas con usuarios.

El aporte previsto es una comparación reproducible que muestre cuándo cada señal ayuda y dónde falla, con perfiles construidos desde adjudicaciones anteriores y etiquetas incompletas. La fuente principal es OCDS/OECE. SEACE se consultará solo como apoyo para documentos asociados. El procesamiento masivo de anexos, PLADICOP y la validación con empresas quedan fuera de esta prueba de concepto. El ODS 8 orienta el interés de aplicación, pero el estudio no medirá un impacto económico.

11. Diseño metodológico

Contribución académica:

La contribución académica será empírica y metodológica. Se compararán métodos léxicos, semánticos e híbridos sobre los mismos perfiles y oportunidades, con registro de fuentes y configuraciones. Las ablaciones permitirán examinar el aporte de cada componente. Una adjudicación será un positivo observado, no una definición completa de compatibilidad. La falta de adjudicación tampoco bastará para considerar una oportunidad incompatible.

Contexto o escenario de aplicación:

La prueba de concepto se limita a oportunidades de servicios en el Perú, obtenidas de OCDS/OECE, y a empresas con antecedentes suficientes para reconstruir un perfil. La ventana histórica comprende 2022–2024 y la colección posterior corresponde a 2025. No se evaluarán empresas sin historial ni se certificará cumplimiento de requisitos legales.

Criterios de inclusión: se considerarán procesos de servicios con identificador trazable, fecha de publicación y texto utilizable. Cada perfil deberá tener al menos dos adjudicaciones anteriores al corte temporal. La consulta será el perfil empresarial y el elemento recuperado será una oportunidad.

Criterios de exclusión: duplicados, procesos fuera del alcance temporal o sectorial y registros sin texto mínimo utilizable. No se exigirá disponer del PDF completo cuando exista texto en el registro publicado. Los atributos ausentes se conservarán como desconocidos y no se interpretarán como incumplimientos.

Técnicas, herramientas o tecnologías:

Se limpiarán los registros sin mezclar la normalización de BM25 con la tokenización propia de LaBSE. Se conservará la procedencia de cada campo y se usará la primera publicación disponible de cada oportunidad. El adjudicatario posterior no entrará al texto que recibe el sistema. Sin embargo, la fecha de una adjudicación histórica no confirma por sí sola cuándo estuvo disponible ese dato. Su disponibilidad requerirá una auditoría de versiones.

Locatelli et al. (2024) y Lima et al. (2026) muestran usos de BERT en contratación pública, aunque sus tareas no consisten en recomendar oportunidades. Aquí se empleará el modelo preentrenado sentence-transformers/LaBSE mediante Sentence Transformers. Los textos largos se dividirán para respetar el límite de tokens. Tras promediar y normalizar los vectores de los fragmentos, cada perfil se formará agregando sus adjudicaciones previas. No se entrenará BERT desde cero ni se tratará Sentence Transformers como un modelo adicional. LaBSE se contrastará con BM25 en este corpus.

La similitud coseno entre los vectores del perfil y de la oportunidad constituye una señal de recuperación. Se contrastará con BM25, que puntúa coincidencias léxicas. La similitud coseno no se utilizará como medida final de calidad del sistema.

El ranking combina las señales léxica y semántica normalizadas con afinidades de categoría, región y monto. La configuración inicial es C = 0,35L + 0,50S + 0,08G + 0,04R + 0,03M. Estos pesos son fijos para el piloto y no se presentan como valores óptimos. Solo se compararán montos positivos y finitos de una misma moneda, tomando como referencia la mediana histórica. Si falta un atributo, su contribución será cero y no se redistribuirá el peso. La explicación señalará la ausencia de datos, que no equivale a incompatibilidad. No se considerarán certificaciones sin evidencia ni se predecirá la adjudicación.

Métricas o criterios de evaluación:

Se reportarán Precision@k, Recall@k y F1@k para k = 5 y 10, calculadas por perfil y luego promediadas. Precision@k divide los positivos observados recuperados entre k. Recall@k los divide entre los positivos conocidos de ese perfil dentro de la colección candidata. F1@k es la media armónica de ambas medidas. Los 50 perfiles del piloto tienen al menos un positivo observado. En futuras cohortes, los perfiles sin positivos se informarán aparte junto con la cobertura. Estas métricas describen recuperación histórica dentro del conjunto experimental, no compatibilidad exhaustiva.

La extracción de objeto, categoría, región, monto y experiencia identificable se contrastará con una anotación manual de 50 oportunidades de la colección candidata. La selección seguirá el orden del hash SHA-256 de sus identificadores, con semilla 42. Se registrará el valor y su fragmento de apoyo, o el estado ausente, ambiguo o ilegible. Los dos últimos estados se contarán aparte y no entrarán al cálculo del campo afectado. Se informarán precisión, exhaustividad y F1 por campo, además de cobertura y tasa de documentos procesables. Este análisis no mide la calidad de los embeddings y no se anunciarán resultados antes de completar la anotación.

Metodología:

Se adopta un enfoque cuantitativo y aplicado, con evaluación computacional retrospectiva. Las cinco etapas corresponden a los objetivos específicos. Etapa 1. Definición de variables y protocolo. Paso 1: delimitar las oportunidades de servicios y la compatibilidad observable. Paso 2: establecer las variables del perfil y de cada oportunidad. Paso 3: fijar el corte temporal, los criterios de selección y las métricas. Paso 4: precisar a qué empresas y candidatos podrán aplicarse los resultados del piloto.

Etapa 2. Construcción del corpus y de los perfiles. Paso 1: conservar los 48 snapshots OCDS/OECE y su procedencia. Paso 2: integrar versiones por OCID, filtrar servicios por la fecha real de publicación y distinguir la primera publicación del desenlace posterior. Paso 3: seleccionar los perfiles según región e historial previo, y formar una colección común de candidatos. El piloto reúne 50 empresas, 317 adjudicaciones anteriores, 1000 oportunidades y 135 pares positivos. Los positivos se incorporan deliberadamente, por lo que la muestra no representa una búsqueda prospectiva. Paso 4: recuperar el texto inicial y agregar los antecedentes de cada empresa sin incorporar adjudicaciones futuras a las entradas.

Etapa 3. Procesamiento textual y representación semántica. Paso 1: reunir y limpiar el título, la descripción y los fragmentos disponibles de la primera publicación, conservando su fuente. Ese texto no equivale a todos los términos de referencia adjuntos. Paso 2: preparar la consulta y el índice léxico de BM25. Paso 3: fragmentar textos largos, obtener vectores con LaBSE y agregar los antecedentes de cada perfil. Paso 4: anotar una muestra para evaluar por separado la extracción de campos. Esta anotación aún no constituye un resultado del piloto.

Etapa 4. Integración y explicación del ranking. Paso 1: calcular BM25 y similitud coseno para los mismos candidatos y normalizar sus puntajes por perfil. Paso 2: obtener afinidades de categoría, región y monto cuando los datos sean comparables. Paso 3: combinar las señales con pesos fijos en las configuraciones previstas. Paso 4: ordenar las oportunidades, resolver empates por OCID y mostrar las primeras cinco o diez con su fuente y la contribución de cada señal. El puntaje no certifica requisitos legales ni estima una probabilidad de adjudicación.

Etapa 5. Evaluación comparativa y análisis. Paso 1: ejecutar BM25, LaBSE, su combinación y el híbrido con atributos sobre la misma colección. Paso 2: calcular las métricas por perfil y promediarlas. Paso 3: interpretar las adjudicaciones como positivos observados, sin convertir los casos restantes en negativos confirmados. Paso 4: revisar errores, datos ausentes y sesgos de selección. Paso 5: conservar archivos, hashes, versiones, código y rankings para reproducir el estudio. Como los positivos del piloto ya se conocen,

cualquier mejora generalizable deberá comprobarse después con un conjunto independiente.

Flujo de trabajo (workflow):

Etapa 1. Variables y protocolo: alcance, separación temporal, criterios y métricas.

Etapa 2. Corpus y perfiles: fuentes, versiones, primeras publicaciones e historial.

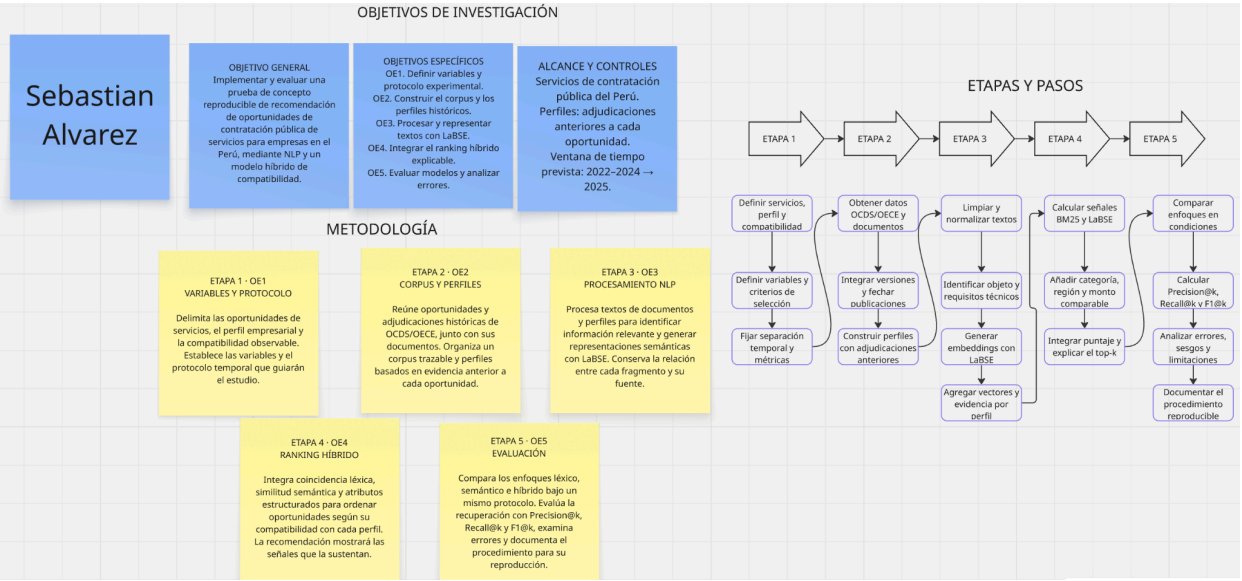
Etapa 3. Procesamiento de lenguaje natural: limpieza, BM25, fragmentación y vectores LaBSE.

Etapa 4. Ranking: señales comparables, combinación y explicación de resultados.

Etapa 5. Evaluación: comparación de variantes, errores y límites de las etiquetas.

Control transversal: trazabilidad, reproducibilidad y distinción entre piloto exploratorio y validación confirmatoria.

Figura 1



Nota: Elaboración propia

12. Referencias

Alma'aitah, W. Z., Quraan, A., AL-Aswadi, F. N., Alkhawaldeh, R. S., Alazab, M., & Awajan, A. (2024). Integration Approaches for Heterogeneous Big Data: A Survey. Cybernetics and Information Technologies, 24(1), 3-20. https://doi.org/10.2478/cait-2024-0001

Alsaif, S. A., Sassi Hidri, M., Ferjani, I., Eleraky, H. A., & Hidri, A. (2022). NLP-Based Bi-Directional Recommendation System: Towards Recommending Jobs to Job Seekers and Resumes to Recruiters. Big Data and Cognitive Computing, 6(4), 147. https://doi.org/10.3390/bdcc6040147

Driel, J. V., Gelderman, C. J., & Semeijn, J. (2026). Exploring SMEs' participation and success in public tenders within the defence sector. Journal of Public Procurement, 1-28. https://doi.org/10.1108/JOPP-12-2024-0128

Lima, W. E. M., Da Silva, V. R., Da Silva, J. C., Rabêlo, R. D. A. L., & De Paiva, A. C. (2026). HelBERT: A BERT-Based Pretraining Model for Public Procurement Tasks in Portuguese. Journal of the Brazilian Computer Society, 32(1), 145-158. https://doi.org/10.5753/jbcs.2026.5511

Locatelli, M., Tagliabue, L. C., & Di Giuda, G. M. (2024). A multi-label text classifier: Application on an Italian public tender procedure, project ISCOL@. Journal of Information Technology in Construction, 29, 864-893. https://doi.org/10.36680/j.itcon.2024.038

Mentzingen, H., António, N., Bacao, F., & Cunha, M. (2024). Textual similarity for legal precedents discovery: Assessing the performance of

machine learning techniques in an administrative court. International Journal of Information Management Data Insights, 4(2), 100247. https://doi.org/10.1016/j.jjimei.2024.100247

Nai, R., Meo, R., Morina, G., & Pasteris, P. (2023). Public tenders, complaints, machine learning and recommender systems: A case study in public administration. Computer Law & Security Review, 51, 105887. https://doi.org/10.1016/j.clsr.2023.105887

Oussalah, M., & Mohamed, M. (2022). Knowledge-based sentence semantic similarity: Algebraical properties. Progress in Artificial Intelligence, 11(1), 43-63. https://doi.org/10.1007/s13748-021-00248-0

Papa, M., Chatzigiannakis, I., & Anagnostopoulos, A. (2024). Automated Natural Language Processing-Based Supplier Discovery for Financial Services. Big Data, 12(1), 30-48. https://doi.org/10.1089/big.2022.0215

Roldan-Baluis, W. L., Zapata, N. A., & Vasquez, M. S. M. (2022). The Effect of Natural Language Processing on the Analysis of Unstructured Text: A Systematic Review. International Journal of Advanced Computer Science and Applications, 13(5). https://doi.org/10.14569/IJACSA.2022.0130507

Siciliani, L., Taccardi, V., Basile, P., Di Ciano, M., & Lops, P. (2023). AI-based decision support system for public procurement. Information Systems, 119, 102284. https://doi.org/10.1016/j.is.2023.102284

Zhang, Y., Zhu, Y., Zhu, Z., Liu, P., Xie, P., & Wu, C. (2025). A Domain-Finetuned Semantic Matching Framework Based on Dynamic Masking and Contrastive Learning for Specialized Text Retrieval. Electronics, 14(24), 4882. https://doi.org/10.3390/electronics14244882